

Memoria proyecto grupo 5

Factores clave en la predicción de la depresión estudiantil mediante el uso de IA

Realizado por:

- Miguel Encina Martinez
- Daniel Galván Cancio
- Jaime Linares Barrera
- Daniel Vela Camacho

1. Resumen

En este documento se especifica el contenido solicitado en la rúbrica de manera explícita. No obstante, sirve como centralización de toda información presentada en los cuadernos .Rmd así como en los HTMLs entregados. El proyecto trata sobre el estudio de la depresión estudiantil, intentando responder a las siguientes preguntas:

- ¿Qué factores provocan depresión en los estudiantes?
- ¿Influye el sexo o el nivel académico?
- ¿Podemos predecir la depresión?

La depresión es un problema muy extendido en la sociedad y que da lugar a consecuencias fatales en algunos casos y, desgraciadamente, en los jóvenes es bastante común. Queremos centrarnos en el sector de los estudiantes para comprobar si los estudios son algo que la condiciona. Los resultados obtenidos muestran que variables relacionadas con la presión académica, el estrés financiero y los pensamientos suicidas tienen un peso significativamente mayor que otras como el sexo o el nivel académico. Este trabajo contribuye a una mejor comprensión de la depresión estudiantil y pone de manifiesto el potencial de los modelos predictivos como apoyo para el análisis y la prevención de problemas de salud mental en el ámbito educativo.

2. Introducción

La depresión es uno de los problemas de salud mental más frecuentes entre estudiantes, con impacto directo en el rendimiento académico y el bienestar personal. Queremos observar sus causas ya que en los últimos años ha aumentado considerablemente, y creemos necesario estudiar este fenómeno. La motivación de este estudio es identificar los factores personales, académicos y de estilo de vida

que más influyen en la presencia de síntomas depresivos, con el fin de mejorar su comprensión y facilitar futuras estrategias de prevención o diagnóstico. Aunque existen múltiples condicionantes asociados a la depresión, no siempre está claro cuáles tienen un mayor impacto ni cómo interactúan entre sí. Además, variables como el sexo o el nivel académico suelen considerarse relevantes, pero su influencia real sigue siendo objeto de debate. La motivación principal de este estudio es contribuir a una mejor prevención y detección de la depresión en estudiantes, identificando los factores personales, académicos y de estilo de vida que más influyen. Para ello se pretende evaluar si es posible predecirla utilizando técnicas de aprendizaje automático. El objetivo del trabajo es analizar un conjunto de datos sobre estudiantes que incluye información demográfica, académica, laboral y de hábitos de vida, con el fin de responder a las siguientes cuestiones: qué factores están más relacionados con la depresión, si variables como el sexo o el nivel académico influyen de manera significativa, y en qué medida pueden construirse modelos predictivos eficaces para anticipar la presencia de depresión.

Para alcanzar estos objetivos, el estudio sigue un pipeline de análisis que comienza con una fase de visualización de los datos para comprender su estructura y detectar patrones relevantes. Después se preprocesan y limpian los datos y, posteriormente, se aplican técnicas de aprendizaje supervisado con validación cruzada y comparación de distintos modelos, así como métodos de explicabilidad para interpretar los resultados. Finalmente, se emplean técnicas de aprendizaje no supervisado con el fin de complementar las conclusiones obtenidas y enriquecer el análisis global del problema.

3. Pipeline software de análisis

3.1 Datos y Análisis exploratorio

Los datos escogidos son un dataset sobre la depresión en estudiantes. Las variables incluyen información personal, académica, laboral y de estilo de vida como edad, género, ciudad, tipo de estudios, trabajo, presión académica, presión laboral, rendimiento (CGPA), satisfacción con los estudios o el empleo, hábitos de sueño/estudio/alimentación. También hay otras variables como las horas dedicadas al estudio o al trabajo, estrés financiero y antecedentes familiares de enfermedades mentales. La variable objetivo es si la persona tiene o no depresión. Nuestro objetivo es entender mejor qué factores pueden relacionarse con síntomas de depresión.

3.2 Análisis

A partir de este dataset, en el primer cuaderno nos centramos en la fase de visualización. Antes de hacer cualquier modelado, realizamos una exploración

completa para entender cómo están estructurados los datos, detectar valores anómalos, ver la distribución de las variables y observar posibles relaciones entre ellas. Esta inspección inicial nos ayudó a identificar qué variables aportan información, cuáles están desbalanceadas y qué patrones podrían ser relevantes para explicar la depresión. También comprobamos que algunas columnas eran constantes o no tenían utilidad real en el análisis y por eso descartamos columnas así como algunos datos (por ejemplo los no estudiantes).

Usamos la exploración bivalente para ver, por ejemplo, que las correlaciones entre las variables numéricas eran muy bajas y que no existían relaciones lineales fuertes entre factores como la edad, las horas de estudio o el rendimiento académico. También comparamos las variables numéricas según el estado de depresión mediante boxplots y gráficos de violín, y analizamos cómo se distribuían distintas categorías en función de la depresión. Esto sirvió para empezar a identificar qué variables podrían tener más peso en el modelado posterior.

En el preprocesamiento formalizamos todo este trabajo previo y lo llevamos a un conjunto de datos limpio y listo para aplicar algoritmos de minería de datos. Entre otros pasos, filtramos únicamente a los estudiantes, eliminamos columnas irrelevantes o constantes y limpiamos valores inconsistentes como el “?” de la variable de estrés financiero. Convertimos las variables binarias (“Yes”/“No”) a formato booleano (1 si “Yes” y 0 si “No”), tratamos adecuadamente las variables ordinales como las horas de sueño y los hábitos dietéticos, y reducimos la complejidad de variables con demasiadas categorías (como ciudades o titulaciones académicas), agrupándolas en niveles más manejables. Además, transformamos las variables categóricas a factores ordenados cuando correspondía y detectamos posibles valores extremos en las variables numéricas, evaluando si era necesario filtrarlos para no distorsionar el análisis. Por último, generamos varios csvs a partir del dataset (normalizado, estandarizado, con selección de atributos mediante información mutua) para adaptarlo a diferentes modelos de aprendizaje supervisados y no supervisados de los cuadernos 3 y 4. Es decir, pasamos de un dataset inicial heterogéneo y con bastante variabilidad a unas versiones depuradas y estructuradas de los datos que sí podíamos usar.

El pipeline de análisis consistió en una fase inicial de exploración y visualización de los datos, seguida de un proceso de preprocesamiento y limpieza para obtener datasets estructurados. Posteriormente, se aplicaron técnicas de aprendizaje supervisado con validación cruzada, se compararon distintos modelos y se interpretaron los resultados mediante métricas de evaluación y métodos de explicabilidad como SHAP. Por último, se aplicaron técnicas de aprendizaje no supervisado para poder obtener reglas de asociación y complementar tanto las conclusiones de lo anterior como el modelo predictivo de aprendizaje supervisado. Además de las reglas de asociación, el aprendizaje no supervisado nos permitió aplicar técnicas de clustering. En ese proceso fue necesario escoger la mejor K

posible, y para ello aplicamos el uso de la Silhouette y el método del Codo. El mejor K resultó ser 3. La técnica de clustering escogida es K-medioídes.

3.3 Discusión de resultados

En cuanto al aprendizaje supervisado, se aplicaron distintos modelos lineales y no lineales (regresión logística, LDA, árbol de decisión, Random Forest, XGBoost y LightGBM), utilizando validación cruzada y un split 70/30. Tras comprobar métricas como el accuracy, la sensibilidad y el F1-score concluimos que el mejor es XGB_MinMax_ML. Tras esto aplicamos SHAP para ver la importancia de las variables que seleccionamos, y dimos respuesta a las 2 primeras preguntas planteadas al inicio.

Con respecto al aprendizaje no supervisado, analizamos el K óptimo, que resultó ser 3. Identificamos que además, cada uno se corresponde a un perfil específico de estudiante:

- Alto riesgo (Cluster 3, rojo): Alta presión académica, estrés financiero y pensamientos suicidas, bajo rendimiento académico y sueño insuficiente. Estudiantes deprimidos
- Riesgo medio (Cluster 1, naranja): Perfil intermedio, zona de alerta que podría evolucionar hacia alto riesgo, aunque comprobamos con la validación externa que no hay mucha diferencia, y debería considerarse también zona de alto riesgo.
- Bajo riesgo (Cluster 2, verde): Buen rendimiento académico, sueño adecuado y bajos niveles de estrés.

Evaluando cada cluster para comprobar si la clasificación es correcta, obtuvimos esto:

- Bajo riesgo: solo 12.6% de depresión, alta especificidad.
- Medio riesgo: 70.5% de depresión, indicando un estado crítico latente.
- Alto riesgo: 80.6% de depresión, confirmando la polarización del riesgo.

Aplicando las reglas de asociación identificamos la siguiente triada tóxica: Presión académica extrema + estrés financiero crítico + pensamientos suicidas.

4. Conclusiones

Podemos concluir que ni el sexo ni el nivel académico influyen en la depresión estudiantil, sino que lo que realmente influye son los pensamientos suicidas, la presión académica y el estrés financiero. En cierto modo, podríamos intentar asociar la presión académica a los niveles académicos, pero eso lo dejamos como trabajo futuro y como punto a tener en cuenta. Lo mismo podría suceder con

el estrés financiero, ya que a mayor nivel de estudios, mayor edad y por tanto, más probabilidad de que los estudios sean más costosos o deban ser financiados por el propio estudiante, elevando sus niveles de estrés y en consecuencia, llevándolo a un estado de malestar que si es continuado en el tiempo podría provocar depresión. También concluimos que es posible predecir de forma precisa si un estudiante tiene depresión gracias a nuestro modelo de XGB_MinMax_ML, y con nuestras reglas de asociación podríamos también respaldar esos resultados así como tener también una idea de si el estudiante está cerca de sufrir depresión, o de cómo puede prevenirla. Por el momento sabemos que la depresión no surge de un factor aislado, sino de combinaciones de estrés académico, financiero y hábitos de vida, lo que sugiere intervenciones estructurales más que solo terapias individuales. La triada tóxica corrobora lo que encontramos en el aprendizaje supervisado, pero además nos mostró que además se puede potenciar la probabilidad de sufrir depresión si añadimos privación de sueño (<5h), hábitos alimenticios pobres y/o carga de trabajo excesiva.

5. IA Utilizada

A lo largo del proyecto hemos utilizado herramientas de IA generativa para corregir errores, refactorizar código e informarnos sobre cómo proceder en determinadas situaciones (por ejemplo solicitando ayuda con la elección de la “k” en el aprendizaje no supervisado). Sobre todo hemos utilizado Gemini y ChatGPT como herramientas de IA, aunque tratamos de usar Microsoft Co-pilot pero no funcionaba correctamente.

He aquí un ejemplo de uso real:

=====

Prompt: Por que me da este error?

Warning message in check.custom.obj(params, objective):

"Argument 'objective' is only for custom objectives. For built-in objectives, pass the objective under 'params'. This warning will become an error in a future version."

Warning message:

"model fit failed for Fold01: eta=0.01, max_depth=3, gamma=0, colsample_bytree=1, min_child_weight=1, subsample=1, nrounds=150 Error in modelFit\$xNames <- colnames(x) :

ALTLIST classes must provide a Set_elt method [class: XGBAltrepPointerClass, pkg: xgboost]

"

... (mensaje acortado para evitar hacer muy largo el documento)

Something is wrong; all the ROC metric values are missing:

ROC Sens Spec

Min. : NA Min. : NA Min. : NA

1st Qu.: NA 1st Qu.: NA 1st Qu.: NA

Median : NA Median : NA Median : NA

Mean :NaN Mean :NaN Mean :NaN

3rd Qu.: NA 3rd Qu.: NA 3rd Qu.: NA

Max. : NA Max. : NA Max. : NA

NA's :27 NA's :27 NA's :27

Error: Stopping

Traceback:

```
1. train.formula(Depression ~ ., data = minmax_train, method = "xgbTree",  
  . trControl = global_control, tuneGrid = grid_xgb, metric = "ROC")  
2. train(x, y, weights = w, ...)  
3. train.default(x, y, weights = w, ...)  
4. stop("Stopping", call. = FALSE)  
5. .handleSimpleError(function (cnd)  
  . {  
  . watcher$capture_plot_and_output()  
  . cnd <- sanitize_call(cnd)  
  . watcher$push(cnd)  
  . switch(on_error, continue = invokeRestart("eval_continue"),  
  . stop = invokeRestart("eval_stop"), error = NULL)  
  . }, "Stopping", base::quote(NULL))
```

=====

También adjuntamos algunos enlaces interesantes donde se incluyen conversaciones con la IA que detallan cómo la hemos utilizado:

1. [Conversación desde la que se extrajo el ejemplo mostrado](#)
2. [Conversación para paralelizar el fichero de supervisado](#)
3. [Conversación para la sintetización de conclusiones](#)

6. Bibliografía

- Shamim, A. (2025). Student Depression Dataset (Version 1) [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/adilshamim8/student-depression-dataset>

- Repositorio del proyecto. (2025). Depresset [Repositorio de código]. GitHub.
<https://github.com/Dangalcan/depresset>
- OpenAI. (2024). ChatGPT [Modelo de lenguaje de gran escala].
<https://chat.openai.com>
- Google. (2024). Gemini [Modelo de lenguaje de gran escala].
<https://gemini.google.com>
- Microsoft. (2024). Microsoft Copilot [Asistente de inteligencia artificial].
<https://copilot.microsoft.com>
- Kuhn, M. (2024). caret: Classification and regression training [Documentación de software]. <https://cran.r-project.org/package=caret>
- Wickham, H. (2024). ggplot2: Create elegant data visualisations using the grammar of graphics [Documentación de software].
<https://cran.r-project.org/package=ggplot2>
- Wickham, H., François, R., Henry, L., & Müller, K. (2024). dplyr: A grammar of data manipulation [Documentación de software].
<https://cran.r-project.org/package=dplyr>
- Greenwell, B. M. (2024). fastshap: Fast approximate SHAP values [Documentación de software]. <https://cran.r-project.org/package=fastshap>
- Mayer, M. (2024). shapviz: SHAP visualizations [Documentación de software].
<https://cran.r-project.org/package=shapviz>
- Revolution Analytics & Weston, S. (2024). doParallel: Foreach parallel adaptor for the parallel package [Documentación de software].
<https://cran.r-project.org/package=doParallel>
- Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., ... Yutani, H. (2024). tidyverse: Easily install and load the tidyverse [Documentación de software]. <https://cran.r-project.org/package=tidyverse>
- Kassambara, A., & Mundt, F. (2024). factoextra: Extract and visualize the results of multivariate data analyses [Documentación de software].
<https://cran.r-project.org/package=factoextra>
- Maechler, M., Rousseeuw, P., Struyf, A., Hubert, M., & Hornik, K. (2024). cluster: Cluster analysis basics and extensions [Documentación de software].
<https://cran.r-project.org/package=cluster>

- Van der Maaten, L. (2024). Rtsne: T-distributed stochastic neighbor embedding using Barnes-Hut implementation [Documentación de software]. <https://cran.r-project.org/package=Rtsne>
- Central Board of Secondary Education. (n.d.). Central Board of Secondary Education (CBSE) – Official website. <https://www.cbse.gov.in/>
- Bar Council of India. (n.d.). Bar Council of India – Official website. <https://www.barcouncilofindia.org/>
- Council of Architecture. (n.d.). Council of Architecture (COA) – Official website. <https://www.coa.gov.in/>
- Pharmacy Council of India. (n.d.). Pharmacy Council of India – Official website. <https://www.pci.nic.in/>
- National Medical Commission. (n.d.). National Medical Commission (NMC) – Official website. <https://www.nmc.org.in/>